

AI Infra全景

四个维度

1. 训练基础设施
2. 推理基础设施
3. 资源与平台基础设施
4. AI编译器与框架基础设施

PagedAttention --> 用操作系统虚拟内存和分页的思想