

计算练习

1. 单 Worker 每个请求执行 40ms、无批处理，理论服务能力约多少

QPS?

$$1 / (40 / 1000) = 25$$

2. 到达速率持续为 30 QPS 时，队列会发生什么？

超过处理能力，请求挤压

3. 延迟数据为 10,11,11,12,12,13,13,14,15,200 ms，分别计

算平均值和中位数，并解释差异。

平均值 31.1 中位数12 平均值容易受极端值的影响

4. LLM 请求 TTFT=180ms，输出 100 Tokens，TPOT=20ms，估算总

延迟。

$$180 + 100 * 20 = 2180\text{ms}$$

5. 模型执行时间始终为 20ms，但端到端 p99 从 30ms 升至 300ms，

列出至少 4 个应检查的位置。

执行时间没有劣化，检查 序列化 Queue wait batch wait