

验收Pt.2

闭卷回答，至少 8/10 正确：

1. Runtime 与 Serving 的边界是什么？
Runtime 是指调用软硬件进行模型输入输出，Serving则是输入从用户到本地以及输出到用户的过程，边界是序列化/反序列化
2. Operator 与 Kernel 为什么不一定一一对应？
3. 因为可能出现多个Operator合成在一个kernel
4. 延迟和吞吐分别描述什么？
延迟描述的是一个请求完成需要的等待时间是一个时间长度描述
吞吐是指系统单位时间可以完成的请求量，是一个容量的描述
5. 并发度提高为什么可能恶化 p99？
6. 并发度提高 --> 每秒的请求可能变多 --> 达到系统处理能力上限后会出现请求堆积-->导致p99 恶化
7. 动态批处理为什么需要最大等待时间？
避免为了凑大Batch Size导致的超长等待反而影响性能
8. 为什么在线服务不能只报告平均延迟？
9. 因为平均延迟受极端值的影响很大
10. Queue Time 上升但 Compute Time 不变说明什么？
说明 序列/反序列化 Batch wait 上升了
11. 为什么请求队列必须有界？
无界会导致请求挤压
12. TTFT 和 TPOT 分别反映什么？
13. TTFT --> Time to first token ,第一个token 输出的等待时间
TPOT --> Time per operate Token ,第一个token 输出后，每一个token输出的时间
14. 为什么性能报告必须记录硬件、软件版本和输入 shape？
因为不同的硬件、软件和输入shape都会对性能造成影响